



ΠΑΝΕΠΙΣΤΗΜΙΟ ΘΕΣΣΑΛΙΑΣ

Πρόγραμμα Σπουδών
Τμήματος Μηχανικών Πληροφορικής Τ.Ε. Λάρισας

**ΠΙΘΑΝΟΛΟΓΙΚΗ ΠΡΟΒΛΕΨΗ ΤΗΣ ΝΟΣΟΥ
COVID-19 ΜΕ ΕΠΑΝΑΛΑΜΒΑΝΟΜΕΝΑ
ΝΕΥΡΩΝΙΚΑ ΔΙΚΤΥΑ**

ΠΤΥΧΙΑΚΗ ΕΡΓΑΣΙΑ

Άρης Παπαδιάς (ΑΜ: 4413109)

Επιβλέπων: Ηλίας Σάββας, Καθηγητής Πανεπιστημίου Θεσσαλίας

ΛΑΡΙΣΑ 2022

*«Εγώ ο Άρης Παπαδιάς, δηλώνω υπεύθυνα ότι η παρούσα Πτυχιακή Εργασία με τίτλο **ΠΙΘΑΝΟΛΟΓΙΚΗ ΠΡΟΒΛΕΨΗ ΤΗΣ ΝΟΣΟΥ COVID-19 ΜΕ ΕΠΑΝΑΛΑΜΒΑΝΟΜΕΝΑ ΝΕΥΡΩΝΙΚΑ ΔΙΚΤΥΑ** είναι δική μου και βεβαιώνω ότι:*

- Σε όσες περιπτώσεις έχω συμβουλευτεί δημοσιευμένη εργασία τρίτων, αυτό επισημαίνεται με σχετική αναφορά στα επίμαχα σημεία.*
- Σε όσες περιπτώσεις μεταφέρω λόγια τρίτων, αυτό επισημαίνεται με σχετική αναφορά στα επίμαχα σημεία. Με εξαίρεση τέτοιες περιπτώσεις, το υπόλοιπο κείμενο της πτυχιακής αποτελεί δική μου δουλειά.*
- Αναφέρω ρητά όλες τις πηγές βοήθειας που χρησιμοποίησα.*
- Σε περιπτώσεις που τμήματα της παρούσας πτυχιακής έγιναν από κοινού με τρίτους, αναφέρω ρητά ποια είναι η δική μου συνεισφορά και ποια των τρίτων.*
- Γνωρίζω πως η λογοκλοπή αποτελεί σοβαρότατο παράπτωμα και είμαι ενήμερος(-η) για την επέλευση των νόμιμων συνεπειών»*

Άρης Παπαδιάς

Ο φοιτητής εντάχθηκε αυτοδίκαια στο Πανεπιστήμιο Θεσσαλίας, σύμφωνα με την παρ. 1 του άρθρου 6 του Ν.4589/2019 (ΦΕΚ 13/Α'/29.01.2019). Η εκπαιδευτική λειτουργία του ανωτέρου προγράμματος σπουδών συνεχίζεται μεταβατικά σύμφωνα με την παρ. 2 του άρθρου 6 του Ν.4589/2019 (ΦΕΚ 13/Α'/29.01.2019).

Εγκρίθηκε από την τριμελή εξεταστική επιτροπή

Τόπος:

Ημερομηνία:

ΕΠΙΤΡΟΠΗ ΑΞΙΟΛΟΓΗΣΗΣ

1.
2.
3.

Περίληψη

Η νόσος COVID-19 υπήρξε μία από τις μεγαλύτερες επιστημονικές προκλήσεις του 21^{ου} αιώνα. Η ταχεία διασπορά και τα αυξημένα ποσοστά θνητότητας, επέφεραν σημαντικές αλλαγές στις λειτουργίες των κρατών και των συστημάτων υγείας. Η έγκαιρη πρόβλεψη των κρουσμάτων και κυρίως των θανάτων από την νόσο, αποτέλεσε τη νούμερο ένα προτεραιότητα των επιστημόνων έτσι ώστε να διασφαλιστεί η κοινωνική ομαλότητα και η αδιατάραχτη λειτουργία των δομών υγείας.

Στο πλαίσιο αυτής της πτυχιακής εργασίας, υλοποιήθηκε μία εφαρμογή βαθιάς μάθησης για την πρόβλεψη των θανάτων από την νόσο COVID-19 στην Ελλάδα, χρησιμοποιώντας τρία διαφορετικά τεχνητά νευρωνικά δίκτυα. Τα νευρωνικά δίκτυα εκπαιδεύονται με πραγματικά δεδομένα 306 ημερών που περιέχουν τους ημερήσιους θανάτους ασθενών από COVID-19. Η ανάπτυξη αυτών των τεχνητών νευρωνικών δικτύων στηρίχθηκε στην αρχιτεκτονική RNN, Deep MLP και LSTM RNN σε συνδυασμό με την χρήση τεχνικών και μεθόδων βαθιάς μάθησης.

Στόχος της παρούσας πτυχιακής εργασίας, είναι η σύγκριση και η εύρεση της καταλληλότερης τεχνικής βαθιάς μάθησης για την πρόβλεψη των θανάτων από την νόσο COVID-19.

Ευχαριστίες

Θα ήθελα να εκφράσω τις ευχαριστίες μου στον επιβλέποντα καθηγητή μου κύριο Σάββα Ηλία που κατά τη διάρκεια τις εκπόνησης τις πτυχιακής μου εργασίας, με τις συμβουλές και την υπομονή του με βοήθησε να την ολοκληρώσω. Θα ήθελα επίσης να ευχαριστήσω την οικογένεια μου, τους φίλους και τους οικείους μου για την εμπιστοσύνη και την στήριξη που μου έδειξαν όλα αυτά τα χρόνια των σπουδών μου. Τέλος, θα πρέπει να ευχαριστήσω ιδιαίτερα τον παιδικό μου φίλο Παντελή Βλάχα για τις συμβουλές και την στήριξή του.

Άρης Παπαδιάς

04/12/2022

Περιεχόμενα

| | |
|---|-----------|
| ΠΕΡΙΛΗΨΗ | I |
| ΕΥΧΑΡΙΣΤΙΕΣ..... | III |
| ΠΕΡΙΕΧΟΜΕΝΑ..... | V |
| 1 ΕΙΣΑΓΩΓΗ | 1 |
| 2 ΒΑΘΙΑ ΜΑΘΗΣΗ (DEEP LEARNING) | 7 |
| 2.1 ΑΝΑΛΥΣΗ DEEP LEARNING | 7 |
| 2.2 ΑΡΧΙΤΕΚΤΟΝΙΚΕΣ DEEP LEARNING | 9 |
| 2.2.1 Το Συνελκτικό Νευρωνικό Δίκτυο..... | 9 |
| 2.2.2 Το Δίκτυο Βαθιάς Πεποίθησης (Deep Belief)..... | 10 |
| 2.2.3 Τα Αναδρομικά Νευρωνικά Δίκτυα | 11 |
| 3 ΤΕΧΝΗΤΑ ΝΕΥΡΩΝΙΚΑ ΔΙΚΤΥΑ..... | 13 |
| 3.1 Η ΛΕΙΤΟΥΡΓΙΑ ΤΟΥ ΤΕΧΝΗΤΟΥ ΝΕΥΡΩΝΑ | 13 |
| 3.2 ΟΡΓΑΝΩΣΗ ΤΩΝ ΝΕΥΡΩΝΙΚΩΝ ΔΙΚΤΥΩΝ ΣΕ ΕΠΙΠΕΔΑ | 15 |
| 3.3 ΜΟΡΦΕΣ ΣΥΝΑΡΤΗΣΗΣ ΕΝΕΡΓΟΠΟΙΗΣΗΣ | 16 |
| 3.4 ΠΡΟΤΕΙΝΟΜΕΝΗ ΜΕΘΟΔΟΛΟΓΙΑ..... | 17 |
| 4 ΠΙΘΑΝΟΛΟΓΙΚΗ ΠΡΟΒΛΕΨΗ ΤΗΣ ΝΟΣΟΥ COVID-19 ΜΕ ΕΠΑΝΑΛΑΜΒΑΝΟΜΕΝΑ ΝΕΥΡΩΝΙΚΑ ΔΙΚΤΥΑ..... | 21 |
| 4.1 ΒΑΘΙΑ ΜΑΘΗΣΗ ΜΕ ΡΥΘΜΟΝ ΚΑΙ PYTORCH..... | 21 |
| 4.2 ΣΧΕΔΙΑΣΗ ΚΑΙ ΥΛΟΠΟΙΗΣΗ ΤΗΣ ΕΦΑΡΜΟΓΗΣ..... | 23 |
| 4.2.1 Αποτελέσματα Deep MLP | 24 |
| 4.2.2 Αποτελέσματα RNN | 28 |
| 4.2.3 Αποτελέσματα LSTM RNN..... | 32 |
| 5 ΣΥΜΠΕΡΑΣΜΑΤΑ..... | 37 |
| ΒΙΒΛΙΟΓΡΑΦΙΑ | 39 |

1 Εισαγωγή

Με την ταχεία ανάπτυξη της επιστήμης και της τεχνολογίας, η τεχνητή νοημοσύνη έχει επίσης εισαγάγει νέες ευκαιρίες ανάπτυξης. Η τεχνολογία μηχανών που βασίζεται στην τεχνολογία υπολογιστών ενσωματώνει διεπιστημονική θεωρητική γνώση, όπως στατιστικά και πολυπλοκότητα αλγορίθμων, η οποία ενισχύει περαιτέρω τα λειτουργικά χαρακτηριστικά της τεχνητής νοημοσύνης. Η Μηχανική Μάθηση (Machine Learning, ML) είναι μια μορφή τεχνητής νοημοσύνης, η οποία παρέχει στα συστήματα τη δυνατότητα να μαθαίνουν και να βελτιώνονται από την εμπειρία, αυτόματα, χωρίς να προγραμματίζονται ειδικά (Mahdavinejad, M.S., Rezvan, M., Barekatin, M., Adibia, P., Barnaghid, P. & Sheth, A.P., 2018). Ωστόσο, η μηχανική εκμάθηση δεν είναι μια σύνθετη διαδικασία, μέσω της οποίας πραγματοποιείται η συνεχής αυτοματοποίηση των συμβατικών κατασκευαστικών και βιομηχανικών πρακτικών, συμπεριλαμβανομένης της διερευνητικής επεξεργασίας δεδομένων, χρησιμοποιώντας νέες έξυπνες τεχνολογίες (Lewis & Denning, 2018). Καθώς οι αλγόριθμοι απορροφούν δεδομένα εκπαίδευσης, είναι δυνατό να παραχθούν πιο ακριβή μοντέλα με βάση αυτά τα δεδομένα. Έτσι, για την έξυπνη ανάλυση αυτών των δεδομένων και για την ανάπτυξη των αντίστοιχων εφαρμογών, οι αλγόριθμοι μηχανικής μάθησης είναι το κλειδί. Για παράδειγμα, ένας προγνωστικός αλγόριθμος θα δημιουργήσει ένα μοντέλο πρόβλεψης. Στη συνέχεια, όταν παρέχονται δεδομένα στο μοντέλο πρόβλεψης, θα ληφθεί μια πρόβλεψη με βάση τα δεδομένα που εκπαίδευσαν το μοντέλο. Οι αλγόριθμοι μάθησης μπορούν να κατηγοριοποιηθούν σε τέσσερις κύριους τύπους, όπως εποπτευόμενη, χωρίς επίβλεψη, ημι-εποπτευόμενη και ενισχυτική μάθηση στην περιοχή.

Εποπτευόμενη Μάθηση

Στην εποπτευόμενη μάθηση (Supervised Learning), ο αλγόριθμος δημιουργεί ένα μαθηματικό μοντέλο από ένα σύνολο δεδομένων που περιέχει τόσο την είσοδο όσο και την επιθυμητή έξοδο. Αυτοί οι αλγόριθμοι εκπαιδεύονται χρησιμοποιώντας παραδείγματα με ετικέτα (label), δηλαδή είναι γνωστές οι εισροές και οι επιθυμητές εξόδους. Σε αυτήν την εκμάθηση, ο αλγόριθμος λαμβάνει ένα σύνολο εισόδων μαζί με τις αντίστοιχες σωστές εξόδους. Ο αλγόριθμος μαθαίνει συγκρίνοντας την πραγματική του

έξοδο με τις σωστές εξόδους για να βρει σφάλματα. Στη συνέχεια, το μοντέλο τροποποιείται ανάλογα. Η ταξινόμηση, η παλινδρόμηση, η πρόβλεψη και η ενίσχυση της κλίσης είναι το παράδειγμα της εποπτευόμενης μάθησης που χρησιμοποιούν μοτίβο για την πρόβλεψη των τιμών. Αυτή η εκμάθηση χρησιμοποιείται συνήθως σε εκείνες τις εφαρμογές όπου τα ιστορικά δεδομένα προβλέπουν μελλοντικά γεγονότα. Η ταξινόμηση και η παλινδρόμηση είναι οι εργασίες που εκτελούνται από την εποπτευόμενη μάθηση. Μερικά παραδείγματα εποπτευόμενης μηχανικής εκμάθησης είναι ο κοντινότερος γείτονας, το Naïve Bayes, το Decision Tree, το Regression Tree κ.λπ.

Μη Εποπτευόμενη Μάθηση

Η μάθηση χωρίς επίβλεψη (Unsupervised learning) είναι ένας τύπος αλγορίθμου που μαθαίνει μοτίβα από δεδομένα χωρίς ετικέτα. Σε αντίθεση με την εποπτευόμενη μάθηση όπου τα δεδομένα επισημαίνονται από έναν ειδικό, οι μέθοδοι χωρίς επίβλεψη επιδεικνύουν αυτοοργάνωση που καταγράφει μοτίβα ως πυκνότητες πιθανότητας ή συνδυασμό προτιμήσεων νευρικών χαρακτηριστικών. Τα άλλα επίπεδα στο φάσμα εποπτείας είναι η ενισχυτική μάθηση όπου η μηχανή λαμβάνει μόνο μια αριθμητική βαθμολογία απόδοσης ως καθοδήγηση και η ημι-εποπτευόμενη μάθηση όπου ένα μικρότερο τμήμα των δεδομένων επισημαίνεται. Δύο ευρείες μέθοδοι στη μάθηση χωρίς επίβλεψη είναι τα νευρωνικά δίκτυα και πιθανολογικές μέθοδοι.

Ημι-εποπτευόμενη Μάθηση

Η ημι-εποπτευόμενη μάθηση (Semi-supervised learning) είναι μια προσέγγιση στη μηχανική μάθηση που συνδυάζει μια μικρή ποσότητα δεδομένων με ετικέτα με μια μεγάλη ποσότητα δεδομένων χωρίς ετικέτα κατά τη διάρκεια της εκπαίδευσης. Η ημι-εποπτευόμενη μάθηση εμπίπτει μεταξύ της μάθησης χωρίς επίβλεψη (χωρίς επισημασμένα δεδομένα κατάρτισης) και της εποπτευόμενης μάθησης (με μόνο επισημασμένα δεδομένα εκπαίδευσης). Είναι μια ειδική περίπτωση αδύναμης εποπτείας.

Ενισχυτική Μάθηση

Εκτός από την εποπτευόμενη μάθηση και την μάθηση χωρίς επίβλεψη, υπάρχουν επίσης μέθοδοι εφαρμογής ενισχυτικής μάθησης (Reinforcement learning) στη μηχανική μάθηση. Η λεγόμενη ενισχυτική μάθηση είναι η συστηματική εκμάθηση ενός

συγκεκριμένου περιεχομένου. Στη συγκεκριμένη διαδικασία υποβολής αίτησης θα χρησιμοποιηθούν τα στοιχεία που συλλέχθηκαν την προηγούμενη περίοδο. Οργανώνονται και επεξεργάζονται οι πληροφορίες ανατροφοδότησης ενός συγκεκριμένου μέρους για να σχηματίσει έναν κλειστό βρόχο επεξεργασίας δεδομένων. Συνολικά, η ενισχυτική μάθηση είναι ένας τύπος μεθόδου μάθησης που επεκτείνει τη συλλογή δεδομένων με βάση τις στατιστικές και τη δυναμική μάθηση. Τέτοιες μέθοδοι χρησιμοποιούνται κυρίως για την επίλυση του προβλήματος ελέγχου των ρομπότ. Οι αντιπροσωπευτικές του μέθοδοι μάθησης περιλαμβάνουν τον αλγόριθμο Q-learning και τον αλγόριθμο εκμάθησης χρονικής διαφοράς.

Επιπρόσθετα, στον τομέα της Τεχνητής Νοημοσύνης, η Βαθιά Μάθηση (Deep Learning) είναι μια μέθοδος που ανήκει στην ευρύτερη οικογένεια των αλγορίθμων Machine Learning που λειτουργεί με βάση την αρχή της μάθησης. Για εκμάθηση, υπό επίβλεψη και χωρίς επίβλεψη, μπορούν να χρησιμοποιηθούν και οι δύο φόρμες. Στη βαθιά μάθηση, ένα μηχανογραφημένο μοντέλο θα εκτελέσει συγκεκριμένο σύνολο εργασιών ταξινόμησης ή ανάλυσης προτύπων με βάση τα δεδομένα που είχαν μάθει προηγουμένως. Για αυτό, ένα μοντέλο πρέπει να εκπαιδευτεί πρώτα με ένα σύνολο επισημασμένων δεδομένων. Η βαθιά εκμάθηση χρησιμοποιείται βασικά για την ταξινόμηση εικόνων, κειμένου ή ήχων. Τα μοντέλα βαθιάς μάθησης λειτουργούν χωρίς ανθρώπινη παρέμβαση και είναι ισοδύναμα, και μερικές φορές ακόμη, ανώτερα από τους ανθρώπους. Τα μοντέλα βαθιάς μάθησης πραγματοποιούνται κυρίως μέσω των βαθιών νευρωνικών δικτύων. Έχει εφαρμοστεί σε πολλούς τομείς που περιλαμβάνουν βιοπληροφορική, επεξεργασία εικόνας, βιομηχανικό αυτοματισμό, επεξεργασία φυσικής γλώσσας, αναγνώριση κειμένου και ήχου και πολλά άλλα.

Η βαθιά μάθηση είναι μια νέα εποχή μηχανικής μάθησης. Η βαθιά μάθηση περιλαμβάνει το υπόδειγμα μάθησης μηχανικής μάθησης τόσο υπό επίβλεψη όσο και χωρίς επίβλεψη. Η μηχανική μάθηση και η βαθιά μάθηση βοηθούν στην παροχή ευφυΐας στο σύστημα που μπορεί να κάνει προβλέψεις για το μέλλον χρησιμοποιώντας δεδομένα του παρελθόντος. Αν θέλουμε να κάνουμε μια σύγκριση των δυνατοτήτων μεταξύ μηχανικής και βαθιάς μάθησης, μπορούμε να σταθούμε στα παρακάτω σημεία:

- Οι συμβατικοί αλγόριθμοι μηχανικής μάθησης δεν μπορούν να μάθουν απευθείας από τα ακατέργαστα δεδομένα. Χρειάζονται προσεκτική μηχανική για να εξαγάγουν προσεκτικά χαρακτηριστικά από ακατέργαστα δεδομένα και εξαιρετικά ταξινομημένα τεχνογνωσία τομέα, τα οποία χρησιμοποιούνται

περαιτέρω σε εσωτερικές αναπαραστάσεις για τον εντοπισμό των μοτίβων αυτών των χαρακτηριστικών. Στο Deep Learning, το πρώτο βήμα της διαδικασίας μηχανικής μάθησης δεν υπάρχει. Αυτό το βήμα είναι αυτοματοποιημένο στη βαθιά μάθηση. Το Deep Learning μπορεί να εξάγει νέες λειτουργίες αυτόματα από ανεπεξέργαστα δεδομένα (J. Latif, C. Xiao, A. Imran, and S. Tu, 2019).

- Οι αλγόριθμοι βαθιάς μάθησης λειτουργούν με μεγαλύτερη ακρίβεια σε μεγάλο σύνολο δεδομένων σε σύγκριση με τους συμβατικούς αλγόριθμους μηχανικής εκμάθησης. Ενώ οι αλγόριθμοι μηχανικής εκμάθησης υπερτερούν της βαθιάς εκμάθησης σε περίπτωση σύνολων δεδομένων μικρού ή μεσαίου μεγέθους (N. G. Paterakis, E. Mocanu, M. Gibescu, B. Stappers, and W. van Alst, 2017).
- Οι αλγόριθμοι βαθιάς μάθησης χρειάζονται λιγότερο χρόνο για να συμπεράνουν ένα πρόβλημα σε σύγκριση με τους συμβατικούς αλγόριθμους μηχανικής μάθησης.
- Η βαθιά μάθηση εκτελεί μεγάλο αριθμό πολλαπλών μήτρας, επομένως χρειάζεται ισχυρή μηχανή κατά προτίμηση GPU (Μονάδες Επεξεργασίας Γραφικών) ή ειδικά σχεδιασμένη TPU (Μονάδες Επεξεργασίας Τενυστήρα), ενώ άλλοι συμβατικοί αλγόριθμοι μηχανικής εκμάθησης μπορούν να λειτουργήσουν σε μηχανές χαμηλού επιπέδου.
- Οι αλγόριθμοι βαθιάς μάθησης είναι δύσκολο έως αδύνατο να ερμηνευτούν. Μερικοί από τους αλγόριθμους μηχανικής μάθησης όπως (logistics, δέντρο αποφάσεων) μπορούν να ερμηνευτούν εύκολα, ενώ κάποιοι (όπως ο SVM) είναι σχεδόν αδύνατο να ερμηνευτούν (M. Sewak, S. K. Sahay, and H. Rathore, 2018).
- Ο χρόνος εκπαίδευσης για τα δεδομένα για τη δημιουργία του μοντέλου είναι περισσότερο στη βαθιά μάθηση σε σύγκριση με άλλους αλγόριθμους μηχανικής εκμάθησης.

Αρκετοί ερευνητές έχουν χρησιμοποιήσει τα μοντέλα μηχανικής μάθησης και βαθιάς μάθησης για να προβλέψουν τη βραχυπρόθεσμη πρόβλεψη της πανδημίας COVID-19. Με αυτόν τον τρόπο, οι επιστημονικές ομάδες και οι κυβερνητικές αρχές, είναι σε θέση να πάρουν μια εκτίμηση σχετικά με τα καθημερινά νέα κρούσματα, το ποσοστό ανάρρωσης, τους συνολικούς θανάτους, κτλ. Επιπλέον μπορεί ευκολότερα να γίνει εκτίμηση για το πόσος χρόνος θα χρειαστεί για να περιοριστεί η εξάπλωση της πανδημίας, βοηθώντας τελικά τις κυβερνήσεις και τα συστήματα υγειονομικής

περίθαλψης να προετοιμαστούν εκ των προτέρων για τον προβλεπόμενο αριθμό κρουσμάτων.

Σκοπός της παρούσας εργασίας είναι η εφαρμογή, η εξέταση και η σύγκριση τριών διαφορετικών νευρωνικών δικτύων (Deep MLP, Elman RNN, LSTM RNN) και τεχνικών Deep Learning για την πρόβλεψη επικείμενων θανάτων από την Νόσο COVID-19. Στο πρώτο κεφάλαιο θα γίνει ανάλυση της Deep Learning, της χρησιμότητάς της όπως και των τεχνικών της. Στο δεύτερο κεφάλαιο, θα γίνει επεξήγηση της εφαρμογής των νευρωνικών δικτύων και θα παρουσιαστούν οι τεχνικές που θα χρησιμοποιηθούν στην παρούσα εργασία. Στο τρίτο κεφάλαιο θα προχωρήσουμε στην υλοποίηση της εφαρμογής και θα αναλυθούν τα αποτελέσματά της. Από τα παραπάνω, στόχο είναι να προκύψουν χρήσιμα συμπεράσματα.

2 Βαθιά Μάθηση (Deep Learning)

2.1 Ανάλυση Deep Learning

Η βαθιά μάθηση είναι ένα σύνολο αλγορίθμων μηχανικής μάθησης που χρησιμοποιεί πολλαπλά επίπεδα που αντιστοιχούν σε διαφορετικό επίπεδο αφαίρεσης σε κάθε επίπεδο. Αποτελείται από στρώμα εισόδου, στρώμα εξόδου και πολλά κρυφά στρώματα (Mosavi A., Varkonyi-Koczy A. R. 2017). Χρησιμοποιείται για σύνθεση φωνής, επεξεργασία εικόνας, αναγνώριση χειρόγραφων κειμένων, ανίχνευση αντικειμένων, αναλυτικές προβλέψεις και λήψη αποφάσεων (Bengio, Y. 2009).

Η βαθιά μάθηση είναι μια συγκεκριμένη μέθοδος μηχανικής μάθησης που ενσωματώνει νευρωνικά δίκτυα σε διαδοχικά επίπεδα προκειμένου να μαθαίνει από δεδομένα με επαναληπτικό τρόπο. Ένα βαθύ νευρωνικό δίκτυο αποτελείται από ένα επίπεδο εισόδου, πολλά κρυφά επίπεδα και ένα στρώμα εξόδου. Κάθε στρώμα περιλαμβάνει πολλές μονάδες που ονομάζονται νευρώνες. Αυτοί οι νευρώνες ονομάζονται επίσης τεχνητοί νευρώνες. Ένας νευρώνας λαμβάνει πολλές εισόδους, εκτελεί ένα σταθμισμένο άθροισμα στις εισόδους του και, στη συνέχεια, το άθροισμα που προκύπτει περνάει από μια συνάρτηση ενεργοποίησης για να παράγει μια έξοδο. Κάθε νευρώνας έχει ένα διάνυσμα βαρών που σχετίζεται με το μέγεθος εισόδου του καθώς και μια προκατάληψη που θα πρέπει να βελτιστοποιηθεί κατά τη διάρκεια της εκπαιδευτικής διαδικασίας

Η βαθιά μάθηση αναζωογόνησε την έρευνα νευρωνικών δικτύων στις αρχές της δεκαετίας του 2000 εισάγοντας μερικά στοιχεία που καθιστούσαν εύκολη την εκπαίδευση βαθύτερων δικτύων. Η εμφάνιση των GPU και η διαθεσιμότητα μεγάλων συνόλων δεδομένων ήταν βασικοί παράγοντες για τη βαθιά μάθηση και ενισχύθηκαν σημαντικά από την ανάπτυξη ανοιχτού κώδικα, ευέλικτων πλατφορμών λογισμικού με αυτόματη διαφοροποίηση όπως Theano, Torch, Caffe, TensorFlow και PyTorch. Αυτό διευκόλυνε την εκπαίδευση περίπλοκων βαθιών δικτύων και την επαναχρησιμοποίηση των πιο πρόσφατων μοντέλων και των δομικών στοιχείων τους. Αλλά η σύνθεση περισσότερων επιπέδων είναι αυτό που επέτρεψε πιο σύνθετες μη γραμμικότητες και πέτυχε εκπληκτικά καλά αποτελέσματα στις εργασίες αντίληψης.

Η θεμελίωση της έννοιας της βαθιάς μάθησης βασίστηκε στην έρευνα τεχνητών νευρωνικών δικτύων. Το γενικό παράδειγμα των μοντέλων που λειτουργούν με βαθιά αρχιτεκτονική είναι ένα πολύ γνωστό νευρωνικό δίκτυο τροφοδοσίας ή πολυστρωματικό perceptron που αποτελείται από πολλά κρυφά στρώματα. Το 1980 εμφανίστηκε και ένας άλλος αλγόριθμος για την εκμάθηση των βαρών αυτών των δικτύων. Το Back-propagation. Ένα τεχνητό νευρωνικό δίκτυο κατασκευάζεται αποτελώντας τρία στρώματα νευρώνων: Στρώμα εισόδου, Επίπεδο εξόδου και ένα ή περισσότερα κρυφά στρώματα που βρίσκονται μεταξύ του επιπέδου εισόδου και εξόδου. Στο τεχνητό νευρωνικό δίκτυο (ANN), μια μαθηματική συνάρτηση χρησιμοποιείται για να αναπαραστήσει έναν νευρώνα, ένα ουσιαστικό στοιχείο του ANN. Οι νευρώνες που κατοικούν σε κάθε στρώμα λαμβάνει μία ή περισσότερες τιμές ως είσοδο, οι οποίες εξάγονται από προηγούμενα στρώματα, εκτός από το στρώμα εισόδου. Συνήθως εκχωρείται ένα βάρος σε κάθε είσοδο και για τον υπολογισμό του αθροίσματος αυτών των τιμών χρησιμοποιείται μια συνάρτηση ενεργοποίησης. Στη βαθιά μάθηση, χρησιμοποιείται ένα βαθύ νευρωνικό δίκτυο που έχει περισσότερο αριθμό κρυφών επιπέδων και που κάνει ένα νευρωνικό δίκτυο «βαθύ». Αυτά τα πολλαπλά επίπεδα χρησιμοποιούνται για την εξαγωγή χαρακτηριστικών και κάθε επίπεδο χρησιμοποιεί την τιμή εξόδου του προηγούμενου επιπέδου ως τιμή εισόδου.

Καθώς τα μοντέλα βαθιάς μάθησης απαιτούν μεγάλο αριθμό κρυφών επιπέδων και τεράστιο όγκο δεδομένων εκπαίδευσης με ετικέτα, απαιτείται μεγάλη υπολογιστική ισχύς. Τα τελευταία χρόνια, μηχανήματα με GPU υψηλής απόδοσης είναι διαθέσιμα στην αγορά. Επίσης, το cloud computing και οι παράλληλες αρχιτεκτονικές αποκτούν τεράστια δημοτικότητα. Τέτοια μηχανήματα υψηλής απόδοσης εξοπλισμένα με τεχνολογία έλευσης καθιστά εύκολη την εφαρμογή μοντέλων βαθιάς μάθησης. Για διαφορετικούς τύπους εργασιών, οι αλγόριθμοι μηχανικής εκμάθησης περιέχουν διάφορες μεθόδους που πρέπει να χρησιμοποιηθούν. Ομοίως, απαιτείται πολύ η εκπαίδευση μοντέλων βαθιάς μάθησης με τεράστιο όγκο δεδομένων. Για αυτές, απαιτούνται μηχανές με υψηλή υπολογιστική ισχύ για να κάνουν τη διαδικασία μάθησης πιο γρήγορη. Επομένως, είναι επιθυμητή η χρήση μοντέλων βαθιάς μάθησης στις εργασίες όπου το μέγεθος ενός συνόλου δεδομένων είναι πολύ μεγάλο και υπάρχουν διαθέσιμες μηχανές υψηλής υπολογιστικής ισχύος.

2.2 Αρχιτεκτονικές Deep Learning

Υπάρχουν δύο βασικοί παράγοντες κατά την εργασία με τη βαθιά μάθηση: Η επεξεργασία είναι πολυεπίπεδη μη γραμμική και η μορφή μάθησης μπορεί να είναι εποπτευόμενη ή μη εποπτευόμενη. Οι δημοφιλείς αρχιτεκτονικές που χρησιμοποιούνται για τη δημιουργία μοντέλων βαθιάς μάθησης είναι το Νευρωνικό Δίκτυο Συνεξέλιξης (Convolution Neural Networks, CNNs), το Δίκτυο Deep Belief και το Αναδρομικό Νευρωνικό Δίκτυο (Recurrent Neural Network, RNN). Για προβλήματα γενικής ταξινόμησης, το Deep Belief Network χρησιμοποιείται ευρέως. Το CNN είναι μια από τις πιο δημοφιλείς αρχιτεκτονικές βαθιάς εκμάθησης που χρησιμοποιείται για την ταξινόμηση εικόνας, κειμένου και ήχου. Επιπλέον, το RNN χρησιμοποιείται όταν τα δεδομένα είναι περισσότερο με τη μορφή αλληλουχίας.

2.2.1 Το Συνελικτικό Νευρωνικό Δίκτυο

Συνήθως, τα βαθιά νευρωνικά δίκτυα εκπαιδεύονται χρησιμοποιώντας μεγάλο όγκο δεδομένων και μαθαίνουν χαρακτηριστικά απευθείας από δεδομένα χωρίς μη αυτόματη εξαγωγή χαρακτηριστικών. Το Συνελικτικό Νευρωνικό Δίκτυο (CNN) είναι ένα από τα πιο διαδεδομένα μοντέλα βαθιάς νευρωνικών δικτύων που διαθέτει τη δυνατότητα αυτόματης εκμάθησης χαρακτηριστικών από δεδομένα εισόδου. Είναι μια ειδική κατηγορία νευρωνικού δικτύου προώθησης τροφοδοσίας και καθώς εξαλείφει τη χειροκίνητη εξαγωγή χαρακτηριστικών, χρησιμοποιείται κυρίως για ταξινόμηση εικόνων και καθιστά τη βαθιά εκμάθηση με υψηλή ακρίβεια. Σε αντίθεση με τη μηχανική εκμάθηση, η χειροκίνητη εξαγωγή χαρακτηριστικών από εικόνες δεν απαιτείται και είναι σε θέση να εκτελέσει μια ολόκληρη εργασία όπως ταξινόμηση εικόνων χωρίς χειροκίνητη παρέμβαση.

Προκειμένου να βελτιωθεί η αποτελεσματικότητα της προπόνησης (training), τα φίλτρα εφαρμόζονται επανειλημμένα. Αυτή η διαδικασία βοηθά στη μείωση του αριθμού των παραμέτρων κατά τη διάρκεια της μαθησιακής διαδικασίας. Η μέγιστη ή μέση υποδειγματοληψία μη επικαλυπτόμενων περιοχών σε χάρτες χαρακτηριστικών εκτελείται σε κάθε επίπεδο συγκέντρωσης. Αυτή η διαδικασία βοηθά στον χειρισμό πιο περίπλοκων χαρακτηριστικών (Min, Seonwoo & Lee, Byunghan & Yoon, Sungroh, 2016). Τα πλήρως συνδεδεμένα στρώματα λειτουργούν ως ένα κανονικό νευρωνικό δίκτυο. Είναι μια τελική φάση εκμάθησης που χαρτογραφεί τα χαρακτηριστικά στα προβλεπόμενα αποτελέσματα. Προς το παρόν, το CNN φαίνεται να είναι μια από τις πιο

αποτελεσματικές αρχιτεκτονικές βαθιάς εκμάθησης λόγω της ικανότητας επεξεργασίας εικόνων, κειμένου και ήχων.

2.2.2 Το Δίκτυο Βαθιάς Πεποίθησης (Deep Belief)

Το δίκτυο βαθιάς πεποίθησης (DBN) αποτελείται από πολλαπλά στρώματα περιορισμένης μηχανής Boltzmann (RBM) και αναπαρίσταται ως γραφικό μοντέλο. Περιέχει πολλά επίπεδα κρυφών μεταβλητών, που έχουν δυαδικές τιμές και ονομάζονται κρυφές μονάδες ή ανιχνευτές χαρακτηριστικών και τυπικά αναπαρίσταται ως στοίβα RBM. Υπάρχει μια συμμετρική σύνδεση μεταξύ των δύο κορυφαίων στρωμάτων και σχηματίζει μια συνειρμική μνήμη. Ωστόσο, τα χαμηλότερα επίπεδα καταναλώνουν συνδέσεις από πάνω προς τα κάτω και κατευθυνόμενες συνδέσεις. Δύο διαφορετικοί τύποι νευρωνικών δικτύων περιέχονται από το DBN. Είναι τα δίκτυα πεποιθήσεων και η RBM. Η εκπαίδευση στο DBN πραγματοποιείται σε δύο στάδια: προ-προπόνηση χωρίς επίβλεψη με μη επισημασμένα δείγματα και στη συνέχεια εποπτευόμενη λεπτομέρεια με επισημασμένα δείγματα.

Η αξιοσημείωτη χρήση των Deep Belief Networks (DBN) είναι στον τομέα της Επεξεργασίας Φυσικής Γλώσσας (NLP). Είναι πολύπλοκο έργο η επεξεργασία μη δομημένης μάζας κειμένου που συλλέγεται από τον Ιστό. Το DBN έχει εφαρμοστεί για την εξαγωγή χαρακτηριστικών οντοτήτων με ακρίβεια και με οριακή χειροκίνητη παρεμβολή. Στο NLP, οι πληροφορίες σχετικά με τη θέση της λέξης διαδραματίζουν σημαντικό ρόλο στην ανάλυση των δεδομένων συναισθήματος. Μια νέα προσέγγιση που χρησιμοποιήθηκε για την ταξινόμηση κειμένων, ενσωματώνοντας πληροφορίες θέσης σε δίκτυα βαθιάς πεποίθησης και για την κατηγοριοποίηση του βιοϊατρικού κειμένου και έδωσε καλύτερα αποτελέσματα. Το DBN έχει επίσης εφαρμοστεί για ταξινόμηση εικόνων και πέτυχε καλή ακρίβεια (S. Zhou, Q. Chen and X. Wang, 2010).

Στον τομέα της Ιατρικής Διάγνωσης, το DBN χρησιμοποιήθηκε για την πρόβλεψη ενός καρδιαγγειακού κινδύνου και της στεφανιαίας νόσου. Επίσης, το DBN εφαρμόστηκε ως ταξινομητής για δεδομένα ΗΚΓ με μεγαλύτερη ακρίβεια σε σύγκριση με το Νευρωνικό Δίκτυο και εφαρμόστηκε σε δεδομένα EEG πολλαπλών καναλιών για την ανίχνευση της πιθανότητας κατάσχεσης. Στην ιατρική διάγνωση, έχουν σχεδιαστεί συστήματα CAD (υποβοηθούμενη από υπολογιστή) που υποστηρίζουν τη μείωση της πιθανότητας εσφαλμένης διάγνωσης, που πιθανότατα προέκυψε λόγω κόπωσης, κούρασης των ματιών ή έλλειψης εμπειρίας. Σε τέτοιες περιπτώσεις, ο ακριβής

ταξινομητής απαιτείται και το DBN χρησιμοποιήθηκε ως ταξινομητής για τη διάγνωση του καρκίνου του μαστού (Mohamed abd el Zaher, Ahmed allah & Eldeib, Ayman. 2015). Στον τομέα της αναγνώρισης ομιλίας, παρουσιάστηκε η χρήση του DBN και παρατηρήθηκε ότι η χρήση του DBN κάνει τη διαδικασία εκπαίδευσης πιο εύρωστη και αποτελεσματική (Farahat, Mahboubbeh & Halavati, Ramin. 2016).

2.2.3 Τα Αναδρομικά Νευρωνικά Δίκτυα

Τα αναδρομικά νευρωνικά δίκτυα (Recurrent Neural Network -RNN) είναι μια αρχιτεκτονική βαθιάς μάθησης που χρησιμοποιείται κυρίως για την επεξεργασία διαδοχικών δεδομένων. Ο τρόπος με τον οποίο λειτουργούν τα RNN, δείχνει καλύτερη απόδοση στον τομέα της επεξεργασίας φυσικής γλώσσας, όπως και στην αναγνώριση κειμένου και ομιλίας. Βασικό πλεονέκτημα του RNN είναι ότι μπορεί να συσσωρεύει τις προηγούμενες πληροφορίες καθώς διαθέτει «μνήμη». Με άλλα λόγια, τα τεχνητά νευρωνικά δίκτυα που βασίζονται σε RNN χρησιμοποιούνται για την εκμάθηση των αλλαγών του χρόνου και των προβλέψεων που αντιστοιχούν σε αυτές. Ο ευρέως χρησιμοποιούμενος τύπος RNN είναι το LSTM (Μακροχρόνια βραχυπρόθεσμη μνήμη).

Τα αναδρομικά νευρωνικά δίκτυα (RNN) έχουν κυκλικές συνδέσεις με την πάροδο του χρόνου. Οι ενεργοποιήσεις από κάθε χρονικό βήμα αποθηκεύονται στην εσωτερική κατάσταση του δικτύου για να παρέχουν μια προσωρινή μνήμη. Αυτή η ικανότητα καθιστά τα RNN καλύτερα κατάλληλα για εργασίες μοντελοποίησης ακολουθίας, όπως εργασίες πρόβλεψης χρονοσειρών και επισημάνσης ακολουθιών.

Η LSTM είναι μια αρχιτεκτονική RNN που σχεδιάστηκε από τους Hochreiter και Schmidhuber για να αντιμετωπίσει τα προβλήματα των συμβατικών (Hochreiter R. & Schmidhuber J. 1997). Τα RNN και τα LSTM έχουν χρησιμοποιηθεί με επιτυχία για την αναγνώριση χειρόγραφου, τη μοντελοποίηση γλώσσας, τη φωνητική σήμανση ακουστικών πλαισίων (Sak, Hasim, Andrew W. & Franoise Beaufays. 2014)

Η αρχιτεκτονική των LSTM αποτελείται από μονάδες που ονομάζονται μπλοκ μνήμης. Το μπλοκ μνήμης περιέχει κελιά μνήμης με αυτο-συνδέσεις που αποθηκεύουν (θυμούνται) τη χρονική κατάσταση του δικτύου εκτός από ειδικές πολλαπλασιαστικές μονάδες που ονομάζονται πύλες για τον έλεγχο της ροής των πληροφοριών. Κάθε μπλοκ μνήμης περιέχει μια πύλη εισόδου για τον έλεγχο της ροής των ενεργοποιήσεων εισόδου στο κύτταρο μνήμης, μια πύλη εξόδου για τον έλεγχο της ροής εξόδου των ενεργοποιήσεων κυψέλης στο υπόλοιπο δίκτυο και μια πύλη λήθης.

3 Τεχνητά Νευρωνικά Δίκτυα


3.1 Η λειτουργία του Τεχνητού Νευρώνα

Τα νευρωνικά δίκτυα υπάρχουν εδώ και πολλά χρόνια και έχουν περάσει από αρκετές περιόδους κατά τις οποίες δεν είχαν προκαλέσει ιδιαίτερο ενδιαφέρον για ενασχόληση με αυτά. Όμως τα τελευταία χρόνια έχουν κερδίσει σταθερά έδαφος έναντι πολλών άλλων ανταγωνιστικών αλγορίθμων μηχανικής μάθησης. Αυτή η αναζωπύρωση του ενδιαφέροντος οφείλεται στην ύπαρξη υπολογιστών που είναι γρήγοροι, στη χρήση μονάδων γραφικής επεξεργασίας (GPU) έναντι της πιο παραδοσιακής χρήσης υπολογιστικών μονάδων επεξεργασίας (CPU), σε καλύτερους αλγόριθμους και σχεδιασμό νευρωνικών δικτύων και σε όλο και μεγαλύτερα σύνολα δεδομένων. Χαρακτηριστικό παράδειγμα της επιτυχίας τους είναι η χρήση τους στην αναγνώριση και ταξινόμηση εικόνων σε κατηγορίες. Αλλά οι αλγόριθμοι βαθιάς μάθησης έχουν διαπρέψει και σε άλλους τομείς. για παράδειγμα, τόσο το Google Now όσο και ο “personal assistant” Siri της Apple βασίζονται σε βαθιά δίκτυα για την αναγνώριση ομιλίας. Επίσης πεδίο χρήσης βρίσκουν και στις μηχανές μετάφρασης της Google.

Μπορούμε να περιγράψουμε ένα νευρωνικό δίκτυο ως ένα μαθηματικό μοντέλο για την επεξεργασία πληροφοριών. Ένα νευρωνικό δίκτυο δεν είναι ένα σταθερό πρόγραμμα, αλλά μάλλον ένα μοντέλο, ένα σύστημα που επεξεργάζεται πληροφορίες ή εισόδους (Jürgen Schmidhuber, 2015). Τα χαρακτηριστικά ενός νευρωνικού δικτύου είναι τα εξής:

- Η επεξεργασία πληροφοριών λαμβάνει χώρα στην απλούστερη μορφή της, πάνω από απλά στοιχεία που ονομάζονται νευρώνες.
- Οι νευρώνες συνδέονται και ανταλλάσσουν σήματα μεταξύ τους μέσω συνδέσμων σύνδεσης.
- Οι σύνδεσμοι μεταξύ των νευρώνων μπορεί να είναι ισχυρότεροι ή πιο αδύναμοι και αυτό καθορίζει τον τρόπο επεξεργασίας των πληροφοριών.
- Κάθε νευρώνας έχει μια εσωτερική κατάσταση που καθορίζεται από όλες τις εισερχόμενες συνδέσεις από άλλους νευρώνες.
- Κάθε νευρώνας έχει μια διαφορετική συνάρτηση ενεργοποίησης που υπολογίζεται στην κατάστασή του και καθορίζει το σήμα εξόδου του.

Βλέπουμε λοιπόν ότι σε ένα τεχνητό νευρωνικό δίκτυο, ο νευρώνας αποτελεί τη βασική δομική μονάδα του. Σε κάθε νευρώνα υπάρχει μια είσοδος πληροφοριών, ακολουθεί ένα στάδιο επεξεργασίας, και στο τέλος δίνεται μια τιμή εξόδου (Πλεύρου, Α. 2012). Η τιμή εξόδου ενός νευρώνα μπορεί να γίνει αντίστοιχα είσοδος σε άλλον νευρώνα. Τα ήδη νευρώνα που υπάρχουν ποικίλουν και ανάλογα με την εφαρμογή που θέλουμε να υλοποιήσουμε μπορούμε να επιλέξουμε το κατάλληλο είδος. (Nielsen, 2015). Φυσικά κατά την υλοποίηση μπορεί να γίνει συνδυασμός διαφορετικών τύπων νευρώνων. Παρακάτω ακολουθεί η σχηματική αναπαράσταση του βασικού μοντέλου του νευρώνα, ο οποίος βρίσκει εφαρμογή σε υλοποιήσεις τεχνητών νευρωνικών δικτύων.



Εικόνα 1: Σχηματική Αναπαράσταση Νευρώνα Τεχνητού Νευρωνικού Δικτύου
(<https://ikee.lib.auth.gr/record/320586/files/Kazaklari%20Fourkiotis.pdf>)

Στο βασικό μοντέλο νευρώνα που μόλις παρουσιάσαμε (Εικόνα 1) μπορούμε να διακρίνουμε 3 κύρια στάδια λειτουργίας:

Στο πρώτο στάδιο έχουμε τις εισόδους (x_1, x_2, \dots, x_i), οι οποίες παραμετροποιούνται αρχικά με το διάνυσμα βάρους που τους αντιστοιχεί ($w_{j1}, w_{j2}, \dots, w_{ji}$). Στο δεύτερο στάδιο, οι σταθμισμένες πλέον εισοδοί αθροίζονται με μία τιμή πόλωσης, η οποία συμβολίζεται με b . Ο παράγοντας πόλωσης μπορεί κατ' αντιστοιχία με τα προηγούμενα, να θεωρηθεί ως μια επιπλέον είσοδος με τιμή εισόδου τη μονάδα και βάρος ίσο με την τιμή του.

Στη συνέχεια, κατά το τρίτο στάδιο εφαρμόζεται μια συνάρτηση ενεργοποίησης ή αλλιώς συνάρτηση μεταφοράς, η οποία ορίζει πώς το σταθμισμένο άθροισμα της εισόδου μετατρέπεται σε έξοδο από έναν κόμβο ή κόμβους σε ένα επίπεδο του δικτύου.

Για να το κατανοήσουμε καλύτερα, ας εξετάσουμε μια ειδική περίπτωση όπου η συνάρτηση ενεργοποίησης είναι $f(x) = x$ και έχουμε μόνο μία τιμή εισόδου, x . Η έξοδος

του νευρώνα γίνεται τότε $y = wx + b$, που είναι η γραμμική εξίσωση. Αυτό δείχνει ότι στον μονοδιάστατο χώρο εισόδου, ο νευρώνας ορίζει μια γραμμή. Εάν απεικονίσουμε το ίδιο για δύο ή περισσότερες εισόδους, θα δούμε ότι ο νευρώνας ορίζει ένα επίπεδο ή ένα υπερεπίπεδο για έναν αυθαίρετο αριθμό διαστάσεων εισόδου. Όπως θα δούμε στη συνέχεια είναι απαραίτητη η οργάνωση των νευρώνων σε ένα τεχνητό νευρωνικό δίκτυο.


3.2 Οργάνωση των Νευρωνικών Δικτύων σε Επίπεδα

Όπως είδαμε προηγουμένως, τα νευρωνικά δίκτυα κατασκευάζονται χρησιμοποιώντας τον νευρώνα ως βασικό δομικό στοιχείο. Οι νευρώνες είναι οργανωμένες ως επίπεδα, με κάθε επίπεδο να περιέχει έναν ή περισσότερους νευρώνες. Το τελευταίο επίπεδο αναφέρεται ως επίπεδο εξόδου. Όλα τα επίπεδα πριν από τα επίπεδα εξόδου αναφέρονται ως κρυφά επίπεδα. Το πρώτο επίπεδο, που συνήθως αναφέρεται ως το επίπεδο 0 και είναι το επίπεδο εισόδου. Κάθε επίπεδο συνδέεται με το επόμενο διαδοχικό επίπεδο με βάρη, τα οποία εκπαιδεύονται/ενημερώνονται με επαναληπτικό τρόπο.

Ο αριθμός των νευρώνων σε ένα επίπεδο αναφέρεται ως το πλάτος του επιπέδου. Ο αριθμός των επιπέδων αναφέρεται ως το βάθος του δικτύου.

Κάθε επίπεδο παίρνει ως είσοδο την έξοδο που παράγεται από το προηγούμενο επίπεδο, εκτός από το πρώτο στρώμα, το οποίο παίρνει την είσοδο του δικτύου. Η έξοδος του τελευταίου επιπέδου είναι η έξοδος του δικτύου και είναι η πρόβλεψη που δημιουργείται με βάση την είσοδο.

Στο παρακάτω διάγραμμα παρουσιάζεται ένα πλήρως συνδεδεμένο νευρωνικό δίκτυο 3 επιπέδων με δύο κρυφά επίπεδα. Το επίπεδο εισόδου έχει k νευρώνες εισόδου, το πρώτο κρυφό επίπεδο έχει n κρυφούς νευρώνες και το δεύτερο κρυφό επίπεδο έχει m κρυφούς νευρώνες. Η έξοδος, σε αυτό το παράδειγμα, είναι οι δύο κλάσεις y_1 και y_2 . Στην κορυφή είναι ο πάντα ενεργός νευρώνας πόλωσης. Μια μονάδα από ένα επίπεδο συνδέεται με όλες τις μονάδες από το προηγούμενο και το επόμενο επίπεδο (άρα πλήρως συνδεδεμένο). Κάθε σύνδεση έχει το δικό της συναπτικό βάρος, w .



Εικόνα 2: Πολυεπίπεδο Νευρωνικό Δίκτυο

(<https://hellanicus.lib.aegean.gr/bitstream/handle/11610/19590/%CE%A4%CE%B5%CE%BB%CE%B9%CE%BA%CE%AE%20%CE%95%CF%81%CE%B3%CE%B1%CF%83%CE%A%CF%84%CE%B1.pdf?sequence=1&isAllowed=y>)

Ανακεφαλαιώνοντας, εισαγάγαμε τον πιο βασικό τύπο νευρωνικού δικτύου, δηλαδή τον νευρώνα, και σταδιακά τον επεκτείναμε σε ένα γράφημα νευρώνων, οργανωμένο σε επίπεδα. Έτσι, καταλάβαμε ότι ο νευρώνας έχει έναν ακριβή μαθηματικό ορισμό. Επομένως, το νευρωνικό δίκτυο, ως σύνθεση νευρώνων, είναι επίσης μια μαθηματική συνάρτηση όπου τα δεδομένα εισόδου αντιπροσωπεύουν τα ορίσματα της συνάρτησης και τα βάρη του δικτύου, w , είναι οι παράμετροί της.

3.3 Μορφές Συνάρτησης Ενεργοποίησης

Τα δίκτυα πολλαπλών επιπέδων μπορούν να ταξινομήσουν γραμμικά αδιαχώριστες κλάσεις. Αλλά για να γίνει αυτό, πρέπει να ικανοποιείται μια ακόμη συνθήκη. Εάν οι νευρώνες δεν έχουν συναρτήσεις ενεργοποίησης, η έξοδος τους θα είναι το σταθμισμένο άθροισμα των εισόδων $\sum_i w_i x_i$ το οποίο είναι μια γραμμική συνάρτηση. Τότε ολόκληρο το νευρωνικό δίκτυο, δηλαδή μια σύνθεση νευρώνων, γίνεται σύνθεση γραμμικών συναρτήσεων, που είναι και γραμμική συνάρτηση. Αυτό σημαίνει ότι ακόμη

και αν προσθέσουμε κρυφά επίπεδα, το δίκτυο θα εξακολουθεί να είναι ισοδύναμο με ένα απλό μοντέλο γραμμικής παλινδρόμησης, με όλους τους περιορισμούς του. Για να μετατρέψουμε το δίκτυο σε μη γραμμική συνάρτηση, θα χρησιμοποιήσουμε μη γραμμικές συναρτήσεις ενεργοποίησης για τους νευρώνες. Συνήθως, όλοι οι νευρώνες στο ίδιο επίπεδο έχουν την ίδια συνάρτηση ενεργοποίησης, αλλά διαφορετικά επίπεδα μπορεί να έχουν διαφορετικές συναρτήσεις ενεργοποίησης. Οι πιο συνηθισμένες συναρτήσεις ενεργοποίησης είναι οι εξής:

- Η γραμμική συνάρτηση ενεργοποίησης $f(x) = x$

$$\phi(x) = \begin{cases} 1, & x \geq 0 \\ 0, & x < 0 \end{cases}$$

- Η βηματική συνάρτηση ενεργοποίησης
- Η λογιστική σιγμοειδής συνάρτηση είναι μια από τις πιο συχνά χρησιμοποιούμενες, καθώς η έξοδος της οριοθετείται μεταξύ 0 και 1 και μπορεί να ερμηνευτεί στοχαστικά ως η πιθανότητα ενεργοποίησης του νευρώνα. Ανήκει στην οικογένεια των σιγμοειδών συναρτήσεων, οι οποίες αποτελούν χαρακτηριστικό παράδειγμα μη γραμμικών συναρτήσεων.

$$\phi(x) = \frac{1}{1 + e^{-x}}$$

- Η επόμενη συνάρτηση ενεργοποίησης η οποία ανήκει επίσης στην οικογένεια των σιγμοειδών συναρτήσεων, ονομάζεται υπερβολική εφαπτομένη

$$\phi(x) = \tanh x$$

Το εύρος για την λογιστική σιγμοειδή συνάρτηση είναι (0, 1), που είναι ένας λόγος για τον οποίο αυτή είναι η προτιμώμενη συνάρτηση για στοχαστικά δίκτυα, με άλλα λόγια, δίκτυα με νευρώνες που μπορούν να ενεργοποιηθούν με βάση μια συνάρτηση πιθανότητας. Η υπερβολική εφαπτομένη συνάρτηση μοιάζει πολύ με την λογιστική συνάρτηση, αλλά το εύρος της είναι (-1, 1).

3.4 Προτεινόμενη Μεθοδολογία

Μέχρι τώρα έχουμε αναπτύξει τη λογική πάνω στην οποία βασίζεται η λειτουργία των νευρωνικών δικτύων. Σε αυτό το στάδιο θα αναλύσουμε το είδος των νευρωνικών δικτύων τα οποία θα μας απασχολήσουν στην υλοποίηση της εφαρμογής για την πρόβλεψη της εξέλιξης της πανδημίας COVID-19. Θα εστιάσουμε κυρίως στα επαναλαμβανόμενα νευρωνικά δίκτυα (RNN) με LSTM. Ο λόγος που τα RNN είναι

προτιμότερα σε σχέση με τις άλλες επιλογές είναι επειδή έχουν εσωτερική μνήμη και παρουσιάζουν τα παρακάτω χαρακτηριστικά.

- Διαθέτουν κρυφή κατάσταση, η οποία ουσιαστικά λειτουργεί σαν μνήμη για αποθήκευση πληροφορίας. Ουσιαστικά στην κρυφή κατάσταση αποθηκεύεται ότι συνέβη στο παρελθόν. Αυτές οι πληροφορίες είναι δυνατό να επηρεάσουν την επεξεργασία κάθε νεοεισερχόμενου δεδομένου.
- Σε αντίθεση με την γραμμική δομή που παρουσιάζουν τα Feed – Forward νευρωνικά δίκτυα, όπου η πληροφορία μεταφέρεται προς μία κατεύθυνση, στα RNN είναι εφικτό η πληροφορία να κατευθύνεται κυκλικά μέσω ενός βρόχου. Με αυτό τον τρόπο, όταν πρέπει να ληφθεί κάποια απόφαση, εκτός από την τρέχουσα εισροή δεδομένων, το RNN επεξεργάζεται και την ήδη αποθηκευμένη πληροφορία.

Με βάση τα παραπάνω θα μπορούσαμε να πούμε ότι τα RNN έχουν δύο εισόδους. Η μία αφορά την εισροή νέων δεδομένων ενώ η δεύτερη την ήδη αποθηκευμένη πληροφορία. Αυτοί οι δύο τύποι εισόδου συνδυάζονται ώστε να καθορίσουν τον τρόπο αντίδρασης σε μια νέα εισροή δεδομένων. Αυτό είναι πιο κοντά και στον ανθρώπινο τρόπο λειτουργίας, καθώς πολλές φορές το κριτήριο λήψης αποφάσεων από τον ανθρώπινο εγκέφαλο, είναι οι προηγούμενες εμπειρίες του (Pengfei L. Xipeng Q. Xuanjing H, 2016).

Αν και στη θεωρία τα RNN φαίνονται ικανά να διαχειριστούν το ζήτημα της διαχείρισης της αποθηκευμένης πληροφορίας και να τη συνδυάσουν με τα νεοεισερχόμενα δεδομένα, εντούτοις στην πράξη παρουσιάζονται δυσχέρειες στην υλοποίηση των παραπάνω για μεγάλα χρονικά διαστήματα, καθώς διαθέτουν βραχυπρόθεσμη μνήμη. Αυτό το πρόβλημα είναι γνωστό ως “Vanishing Gradient Problem”. Σε αυτό το πρόβλημα έρχονται να δώσουν λύση τα LSTM, τα οποία διαθέτουν και μακροπρόθεσμη μνήμη. Μέσω των μπλοκ μνήμης που διαθέτουν τα LSTM, βοηθάνε στη διατήρηση της πληροφορίας και κατά συνέπεια στη διατήρηση της μάθησης στο δίκτυο, ακόμα και αν υπάρχουν πολλά κρυμμένα επίπεδα.

Τα LSTM διαθέτουν αρχιτεκτονική, η οποία είναι αρκετά κοντινή με τα RNN με τη διαφορά ότι χρησιμοποιούν διαφορετική συνάρτηση για τον υπολογισμό της κρυμμένης κατάστασης. Η αρχιτεκτονική των LSTN αποτελείται από ανεξάρτητα υποδίκτυα συνδεδεμένα μεταξύ τους τα οποία αποκαλούνται μπλοκ μνήμης όπως αναφέραμε

προηγούμενως. Τα μπλοκ μνήμης διαθέτουν μια πύλη εισόδου, μία εξόδου και μία forget οι οποίες διαθέτουν μια σιγμοειδή συνάρτηση, η οποία έχει εύρος τιμών $(0, 1)$ το οποίο καθορίζει τον τρόπο που θα περάσει η πληροφορία στη μνήμη. Στην τιμή 0 η πληροφορία δεν περνάει ενώ στην τιμή 1 περνάει αυτούσια (Thomas, 2018).

4 Πιθανολογική Πρόβλεψη της Νόσου COVID-19 με Επαναλαμβανόμενα Νευρωνικά Δίκτυα

4.1 Βαθιά Μάθηση με Python και Pytorch

Από τη δημιουργία της, τον Φεβρουάριο του 1991, η Python έγινε αργά αλλά σταθερά η πέμπτη πιο χρησιμοποιούμενη γλώσσα προγραμματισμού τη δεκαετία του 2020. Αυτή η επιτυχία αποδίδεται συχνά στην υψηλή του απόδοση σε σύγκριση με άλλες κύριες γλώσσες προγραμματισμού, καθώς και στις εντολές και τη σύνταξη που μοιάζουν με τα αγγλικά, που το καθιστούν εύκολο στην εκμάθηση και τη χρήση του ακόμα και για αρχάριους κωδικοποίησης.

Ένα από τα πιο ωφέλιμα χαρακτηριστικά της Python είναι η πληθώρα των βιβλιοθηκών ανοιχτού κώδικα. Μπορούν να χρησιμοποιηθούν σε οτιδήποτε, από την επιστήμη δεδομένων και την οπτικοποίηση έως τη χειραγώγηση εικόνων και δεδομένων. Τα πιο πρόσφατα χρόνια, ωστόσο, αρκετές βιβλιοθήκες Python έχουν χαράξει μια αναμφισβήτητη παρουσία στον κόσμο της μηχανικής μάθησης (ML) και της βαθιάς μάθησης (DL).

Η PyTorch είναι μια βιβλιοθήκη για προγράμματα Python που διευκολύνει τη δημιουργία project βαθιάς μάθησης. Δίνει έμφαση στην ευελιξία και επιτρέπει στα μοντέλα βαθιάς μάθησης να εκφράζονται σε Python. Αυτή η προσιτότητα και η ευκολία στη χρήση βρήκε από πολύ νωρίς χρήστες στην ερευνητική κοινότητα και μάλιστα στα χρόνια από την πρώτη κυκλοφορία της, έχει εξελιχθεί σε ένα από τα πιο σημαντικά εργαλεία βαθιάς μάθησης σε ένα ευρύ φάσμα εφαρμογών.

Όπως κάνει η Python για τον προγραμματισμό, αντίστοιχα η PyTorch παρέχει μια εξαιρετική εισαγωγή στη βαθιά μάθηση. Ταυτόχρονα, η PyTorch έχει αποδειχθεί ότι είναι πλήρως καταρτισμένη για χρήση σε επαγγελματικά πλαίσια και σε πραγματικές εργασίες υψηλού προφίλ. Θα μπορούσαμε να πούμε ότι η σαφής σύνταξη, το βελτιωμένο API και

ο εύκολος εντοπισμός σφαλμάτων της PyTorch την καθιστούν εξαιρετική επιλογή για την εισαγωγή της βαθιάς μάθησης.

Όπως είπαμε, η βαθιά μάθηση μας επιτρέπει να εκτελούμε ένα πολύ ευρύ φάσμα περίπλοκων εργασιών, όπως η αυτόματη μετάφραση, τα παιχνίδια στρατηγικής ή η αναγνώριση αντικειμένων, προσώπων κτλ. Για να το κάνουμε αυτό στην πράξη, χρειαζόμαστε εργαλεία που να είναι ευέλικτα, ώστε να μπορούν να προσαρμοστούν σε τόσο μεγάλο εύρος προβλημάτων και αποτελεσματικά, ώστε να επιτρέπεται η εκπαίδευση σε μεγάλες ποσότητες δεδομένων σε λογικούς χρόνους. Οι κυριότεροι λόγοι που καθιστούν την επιλογή της Pytorch παρουσιάζονται παρακάτω.

Το PyTorch προτείνεται γενικά λόγω της απλότητάς της. Πολλοί ερευνητές και επαγγελματίες την βρίσκουν εύκολη στην εκμάθηση, τη χρήση, την επέκταση και τον εντοπισμό σφαλμάτων. Η χρήση της βιβλιοθήκης είναι γενικά οικεία στους προγραμματιστές που έχουν χρησιμοποιήσει στο παρελθόν Python.

Πιο συγκεκριμένα, ο προγραμματισμός της μηχανής βαθιάς εκμάθησης είναι πολύ φυσικός στην PyTorch. Η PyTorch μας δίνει έναν τύπο δεδομένων, το Tensor, για να κρατάμε αριθμούς, διανύσματα, πίνακες ή πίνακες γενικά. Επιπλέον, παρέχει συναρτήσεις για τη λειτουργία τους. Μπορούμε να προγραμματίσουμε με αυτά σταδιακά και, αν θέλουμε, διαδραστικά, όπως ακριβώς έχουμε συνηθίσει από την Python.

Επιπλέον η PyTorch προσφέρει δύο δυνατότητες που την καθιστούν ιδιαίτερα σημαντική για τη βαθιά μάθηση: πρώτον, παρέχει επιταχυνόμενους υπολογισμούς χρησιμοποιώντας μονάδες γραφικής επεξεργασίας (GPUs), συχνά αποδίδοντας ταχύτητες στην περιοχή 50x σε σχέση με τον ίδιο υπολογισμό σε μια CPU. Δεύτερον, η PyTorch παρέχει εγκαταστάσεις που υποστηρίζουν αριθμητική βελτιστοποίηση σε γενικές μαθηματικές εκφράσεις, τις οποίες χρησιμοποιεί η βαθιά μάθηση για εκπαίδευση. Δεδομένου ότι και τα δύο χαρακτηριστικά είναι χρήσιμα για επιστημονικούς υπολογισμούς γενικά και όχι αποκλειστικά για βαθιά μάθηση. Στην πραγματικότητα, μπορούμε με ασφάλεια να χαρακτηρίσουμε την PyTorch ως μια βιβλιοθήκη υψηλής απόδοσης με υποστήριξη βελτιστοποίησης για επιστημονικούς υπολογισμούς στην Python.

Η PyTorch παρουσιάζει επίσης εξαιρετική εξέλιξη. Ενώ αρχικά επικεντρώθηκε σε ερευνητικές ροές εργασίας, πλέον μπορεί να χρησιμοποιηθεί για την ανάπτυξη μοντέλων για συμπερασματικά στοιχεία χωρίς να βασίζεται στην Python, και μπορεί να χρησιμοποιηθεί για σχεδιασμό και εκπαίδευση μοντέλων σε C++. Έχει επίσης αναπτύξει

συνδέσεις με άλλες γλώσσες και διεπαφή για ανάπτυξη σε κινητές συσκευές. Αυτά τα χαρακτηριστικά μας επιτρέπουν να εκμεταλλευτούμε την ευελιξία της PyTorch και ταυτόχρονα να μεταφέρουμε τις εφαρμογές μας ενώ αντίθετα θα ήταν δύσκολο να επιτευχθεί ένας πλήρης χρόνος εκτέλεσης Python ή θα απαιτούσε σημαντικά έξοδα.

4.2 Σχεδίαση και υλοποίηση της εφαρμογής

Στόχος της εφαρμογής είναι η πρόβλεψη των επικείμενων θανάτων την επόμενη ημέρα, χρησιμοποιώντας δεδομένα από έναν συγκεκριμένο αριθμό ημερών που δίνεται στην είσοδο του νευρωνικού δικτύου (`timesteps_input`). Συγκεκριμένα στην υλοποίηση της εφαρμογής θέτουμε `timesteps_input=6`. Τα δεδομένα που χρησιμοποιήθηκαν είναι ο αριθμός των θανάτων από τις 15/09/2021, μέχρι και τις 01/03/2022 στην Ελλάδα. Ο συνολικός αριθμός των ημερών είναι 306 (αριθμός δειγμάτων).

Τα δεδομένα χωρίζονται σε δεδομένα εισόδου και δεδομένα εξόδου. Για κάθε ημέρα, οι θάνατοι των προηγούμενων έξι ημερών χρησιμοποιούνται για το διάνυσμα της εισόδου, και οι θάνατοι στην ημέρα ως έξοδος. Για μία ημέρα πρόβλεψης, το διάνυσμα εισόδου και το διάνυσμα εξόδου αποκαλείται ένα δείγμα (sample).

Η εκπαίδευση των νευρωνικών δικτύων (training) βασίζεται στην αντίστροφη διάδοση σφαλμάτων και παραγώγων (error backpropagation) με σκοπό την ελαχιστοποίηση του σφάλματος (loss function). Για την αποφυγή μεγάλων τιμών παραγώγων (gradient explosion), καθώς και για την αποφυγή της σύγκλισης παραγώγων στο μηδέν (vanishing gradients), τα δεδομένα μετασχηματίζονται στο διάστημα [0, 1] (zero one scaler). Ο μετασχηματισμός είναι:

$$x_{trans} = \frac{x - x_{min}}{x_{max} - x_{min}}$$

Στην παρακάτω ανάλυση εξετάζουμε τρία νευρωνικά δίκτυα:

- ένα βαθύ νευρωνικό δίκτυο αποτελούμενο από 6 επίπεδα (deep feedforward multilayered perceptron, i.e. **Deep MLP**)
- να αναδρομικό νευρωνικό δίκτυο (recurrent neural network, **RNN**)
- ένα αναδρομικό νευρωνικό δίκτυο (RNN) με αρχιτεκτονική Long Short-Term Memory (**LSTM RNN**)

Όσον αφορά την αρχιτεκτονική του πρώτου νευρωνικού, χρησιμοποιείται ένα νευρωνικό με 6 γραμμικά επίπεδα (layers), που ενδιάμεσα τους παραβάλλεται η μη-γραμμικότητα CELU. Το πρώτο επίπεδο έχει 6 εισόδους, και 25 εξόδους. Τα ενδιάμεσα επίπεδα έχουν 25 εισόδους και 25 εξόδους, ενώ το τελευταίο επίπεδο έχει 1 έξοδο. Μετά το τελευταίο επίπεδο, ακολουθεί μια μη γραμμικότητα ειδικά σχεδιασμένη να μετασχηματίζει την είσοδο στο διάστημα $[0,1]$, σε συμφωνία με τον μετασχηματισμό των δεδομένων (TanhPlus):

$$y = 0.5 \tanh(x) + 0.5$$

Όπου χρησιμοποιείται η συνάρτηση υπερβολικής εφαπτομένης.

Το RNN, χρησιμοποιείται ένα επίπεδο με 12 εσωτερικού κρυμμένους νευρώνες (hidden size). Η μονοδιάστατη έξοδος της πρόβλεψης (θάνατοι την επόμενη ημέρα) προκύπτει από ένα πρόσθετο γραμμικό επίπεδο (Linear layer) στην έξοδο, που μετασχηματίζει τους 12 εσωτερικούς νευρώνες σε έναν, σε συνδυασμό με την προαναφερθείσα ειδικά σχεδιασμένη μη-γραμμικότητα TanhPlus.


Το LSTM RNN, χρησιμοποιείται ένα επίπεδο LSTM RNN με 32 κρυμμένους νευρώνες, ένα γραμμικό νευρωνικό που μετασχηματίζει τους 32 σε 1, και μια μη-γραμμικότητα TanhPlus πριν την τελική έξοδο.

Για την εκπαίδευση των νευρωνικών τα δεδομένα χωρίζονται σε παρτίδες (batches) αποτελούμενες από 32 δείγματα (samples). Συνολικά χρησιμοποιούνται το 80% των δεδομένων για μάθηση και το 20% για επαλήθευση. Τα νευρωνικά δίκτυα εκπαιδεύονται για 1000 εποχές (epochs). Μια εποχή τελειώνει όταν όλα τα δεδομένα έχουν περάσει μία φορά διαδοχικά από το νευρωνικό. Το σφάλμα που χρησιμοποιείται για την εκπαίδευση των δεδομένων είναι το μέσο τετραγωνικό σφάλμα (Mean Squared Error, MSE) μεταξύ της πρόβλεψης του νευρωνικού και της πραγματικής τιμής.

4.2.1 Αποτελέσματα Deep MLP


Η εξέλιξη του σφάλματος στην εκμάθηση του Deep MLP φαίνεται στο παρακάτω διάγραμμα (Εικόνα 3). Παρατηρείται ότι και το σφάλμα στο σύνολο δεδομένων εκπαίδευσης (train dataset) μειώνεται δραστικά στις 200 πρώτες εποχές, και μετά σταθεροποιείται. Το ίδιο συμβαίνει και με τα δεδομένα επαλήθευσης (validation dataset). Το καλύτερο μοντέλο, αυτό με το μικρότερο σφάλμα στο validation dataset αποθηκεύεται

στην 900ή εποχή. Αυτό το μοντέλο θα χρησιμοποιηθεί παρακάτω για την πρόβλεψη των θανάτων σε όλο το χρονικό διάστημα των δεδομένων.




Εικόνα 3: Γράφημα εκπαίδευσης του νευρωνικού Deep MLP, σε διάστημα χιλίων εποχών.

Στο επόμενο διάγραμμα (Εικόνα 4), φαίνονται οι προβλέψεις του νευρωνικού (άξονας y) σε συνάρτηση με τις πραγματικές τιμές. Μια τέλεια πρόβλεψη θα έπεφτε ακριβώς πάνω στην συνάρτηση $y=x$ σχεδιασμένη με κόκκινο χρώμα. Παρατηρείται μια πολύ καλή συμφωνία μεταξύ των προβλέψεων του νευρωνικού και των πραγματικών τιμών.



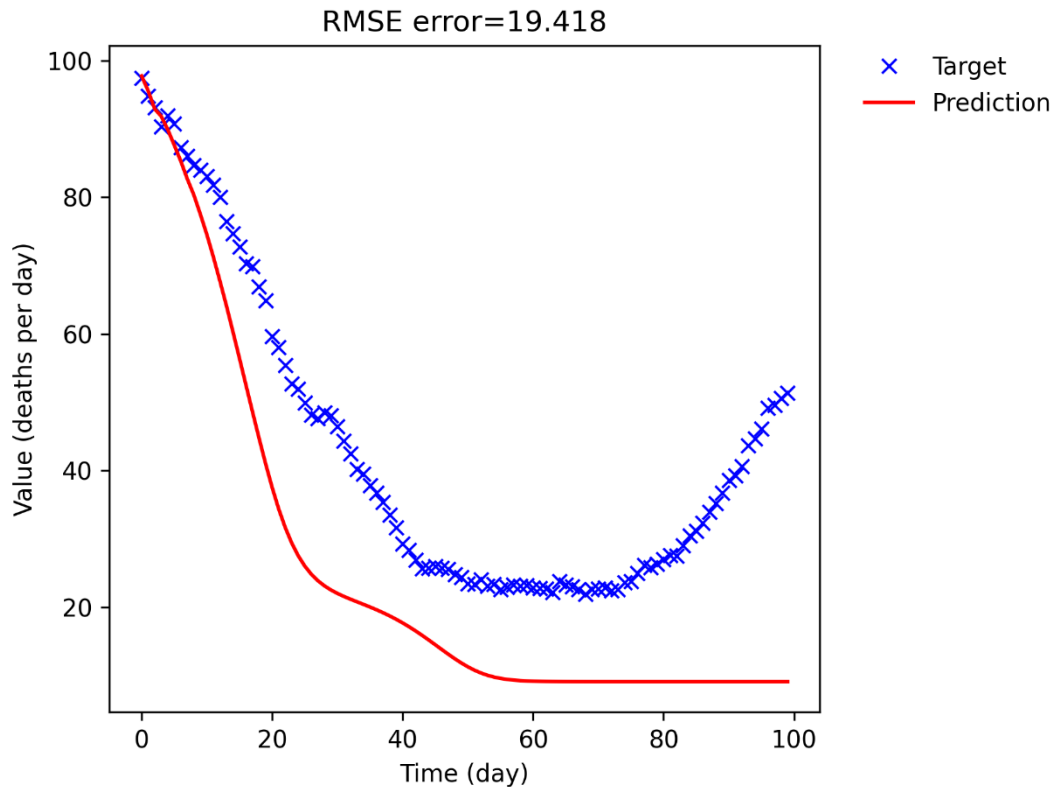
Εικόνα 4: Γράφημα προβλέψεων του νευρωνικού Deep MLP, σε συνάρτηση με τις πραγματικές τιμές

Στο επόμενο διάγραμμα (Εικόνα 5), σχεδιάζονται οι προβλέψεις του νευρωνικού στον χρόνο, όταν στην είσοδο του παρέχονται πραγματικά δεδομένα από τις 6 προηγούμενες μέρες. Παρατηρείται ότι το νευρωνικό μπορεί πολύ αποτελεσματικά να προβλέψει τους θανάτους της επόμενης ημέρας. Η ρίζα του μέσου τετραγωνικού σφάλματος (Root Mean Square Error, RMSE) είναι 1.387 θάνατοι.



Εικόνα 5: Γράφημα προβλέψεων θανάτων από COVID-19 κάθε επόμενης ημέρας, με παραχώρηση των δεδομένων των 6 προηγούμενων ημερών (Deer MLP).

Οι προβλέψεις του νευρωνικού μπορούν να χρησιμοποιηθούν ως επιπλέον δεδομένα διαδοχικά με σκοπό την επίτευξη προβλέψεων για περισσότερες μέρες στο μέλλον. Δηλαδή οι πρώτες έξι μέρες μπορούν να χρησιμοποιηθούν για να προβλεφθούν οι θάνατοι στην έβδομη ημέρα. Η πρόβλεψη μπορεί να χρησιμοποιηθεί μετέπειτα ως επιπλέον είσοδος (υποθέτοντας ότι είναι μια ακριβή περιγραφή της πραγματικότητας) για την πρόβλεψη των θανάτων της 8^{ης} ημέρας. Οι διαδοχικές προβλέψεις που προκύπτουν από αυτή τη διαδικασία διαδοχικών προβλέψεων (iterative forecasting) απεικονίζονται στο επόμενο διάγραμμα (Εικόνα 6):




Εικόνα 6: Γράφημα προβλέψεων θανάτων από COVID-19 σε διάστημα 100 ημερών, με παραχώρηση των δεδομένων των πρώτων 6 ημερών (Deep MLP).

Παρατηρείται ότι παρόλο που το νευρωνικό μπορεί να προβλέψει με ακρίβεια την επόμενη ημέρα, όταν οι προβλέψεις του χρησιμοποιηθούν διαδοχικά, οδηγείται σε μια διαδοχική διάδοση σφαλμάτων (iterative error propagation). Αυτό έχει ως αποτέλεσμα το σφάλμα να διογκώνεται όσο μεγαλώνει ο ορίζοντας πρόβλεψης σε ημέρες. Το συνολικό RMSE σε αυτή την περίπτωση είναι πολύ μεγαλύτερο, 19.418 θάνατοι.

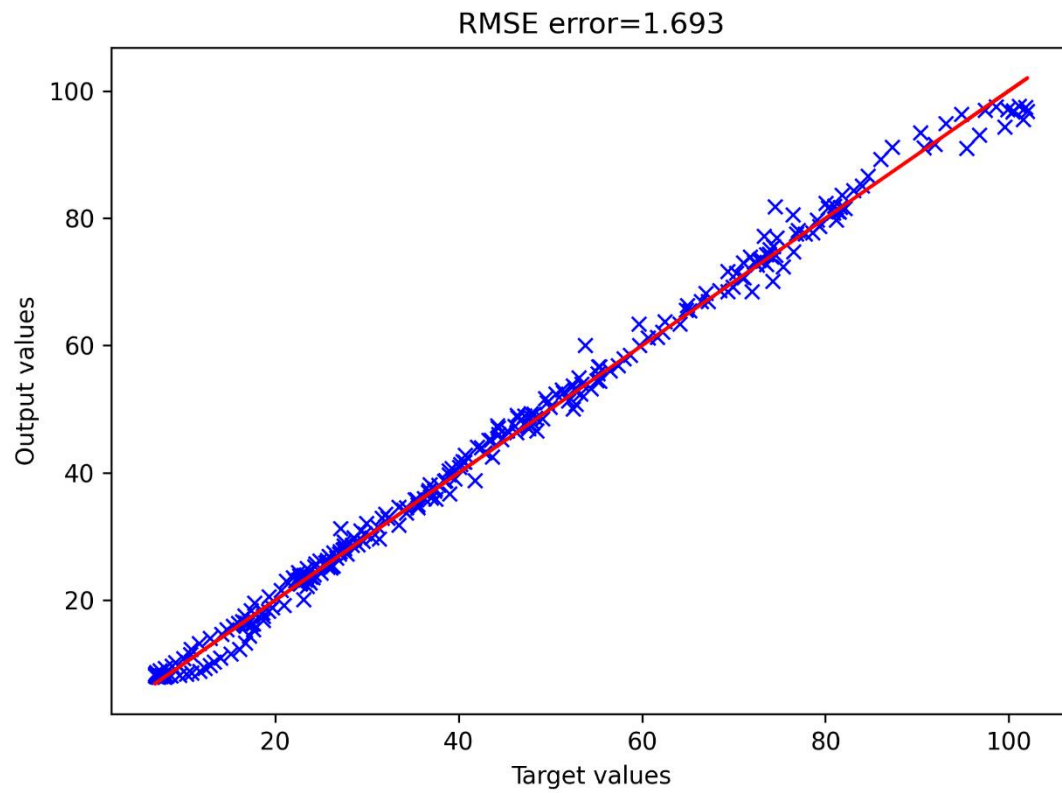
4.2.2 Αποτελέσματα RNN

Η εξέλιξη του σφάλματος στην εκμάθηση του RNN φαίνεται στο παρακάτω διάγραμμα (Εικόνα 7). Παρατηρείται ότι μετά την 700η εποχή, το validation error αυξάνεται. Αυτό δείχνει ότι το μοντέλο ξεκινάει να μαθαίνει χαρακτηριστικά του train dataset που δεν γενικεύονται στο validation dataset (overfitting).




Εικόνα 7: Γράφημα εκπαίδευσης του νευρωνικού RNN σε διάστημα χιλίων εποχών.

Στα επόμενα διαγράμματα (Εικόνα 8 & Εικόνα 9) φαίνονται οι προβλέψεις του RNN στον χρόνο και σε σχέση με τις πραγματικές τιμές. Παρατηρείται ότι το RMSE (1.69) είναι μικρότερο σε σχέση με το Deep MLP.

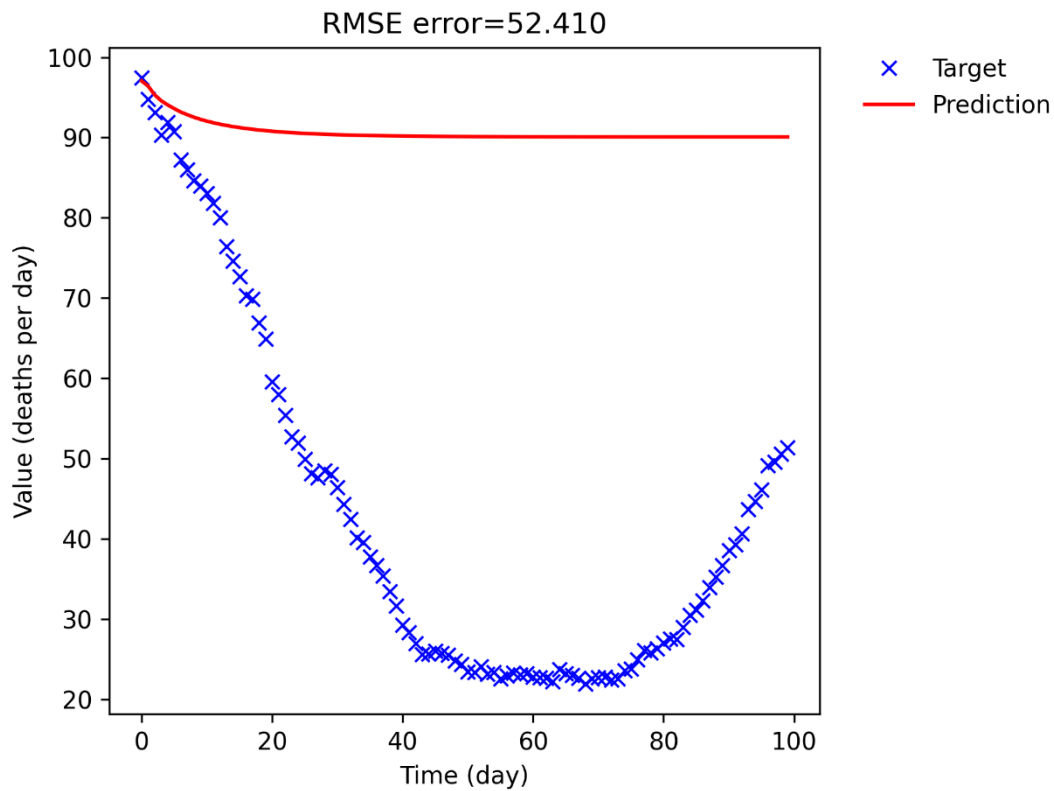


Εικόνα 8: Γράφημα προβλέψεων του νευρωνικού RNN σε συνάρτηση με τις πραγματικές τιμές.



Εικόνα 9: Γράφημα προβλέψεων θανάτων από COVID-19 κάθε επόμενης ημέρες, με παραχώρηση των δεδομένων των 6 προηγούμενων ημερών (RNN).


Στη συνέχεια, χρησιμοποιούνται διαδοχικά οι προβλέψεις του RNN διαδοχικά για πρόβλεψη παραπάνω από μία ημέρα. Οι προβλέψεις φαίνονται στο επόμενο διάγραμμα (Εικόνα 10). Παρατηρείται ότι η πρόβλεψη σταθεροποιείται σχετικά γρήγορα, μετά από δέκα ημέρες στον αριθμό 90 θανάτων. Το συνολικό RMSE είναι μεγαλύτερο από το Deep MLP, 52.410 θάνατοι σφάλμα ανά ημέρα, σε σχέση με 19.418. Αυτό αποδεικνύει ότι παρόλο που ένα μοντέλο έχει καλύτερα αποτελέσματα στην πρόβλεψη της επόμενης ημέρας, αυτό δε σημαίνει ότι το ίδιο μοντέλο είναι καταλληλότερο για διαδοχικές προβλέψεις σε μεγαλύτερους ορίζοντες στο μέλλον.



Εικόνα 10: Γράφημα προβλέψεων θανάτων από COVID-19 σε διάστημα 100 ημερών, με παραχώρηση των δεδομένων των πρώτων 6 ημερών. (RNN).


4.2.3 Αποτελέσματα LSTM RNN

Η εξέλιξη του σφάλματος για το LSTM RNN φαίνεται στο παρακάτω διάγραμμα (Εικόνα 11).

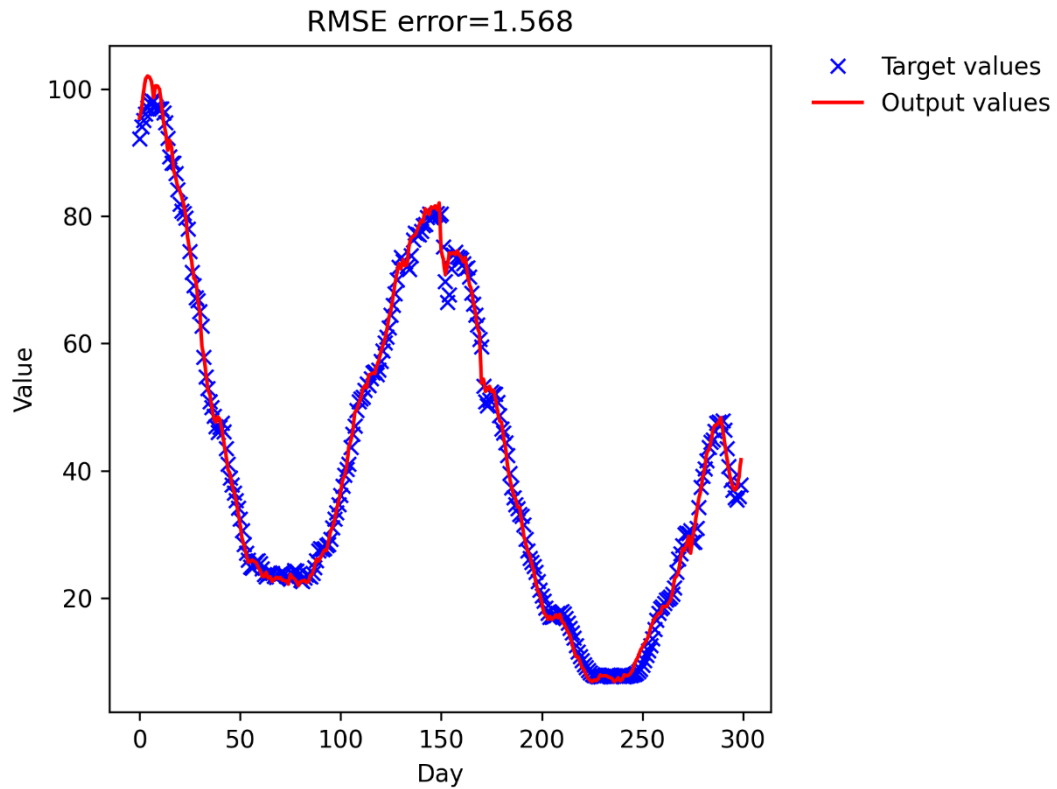


Εικόνα 11: Γράφημα εκπαίδευσης του νευρωνικού LSTM RNN σε διάστημα χιλίων εποχών.

Οι προβλέψεις του νευρωνικού για τους θανάτους της επόμενης ημέρας στο χρόνο, χρησιμοποιώντας πραγματικά δεδομένα για τις προηγούμενες 6 (teacher forcing) φαίνονται στο παρακάτω διάγραμμα (Εικόνα 13). Το LSTM έχει το μικρότερο RMSE, 1.568.

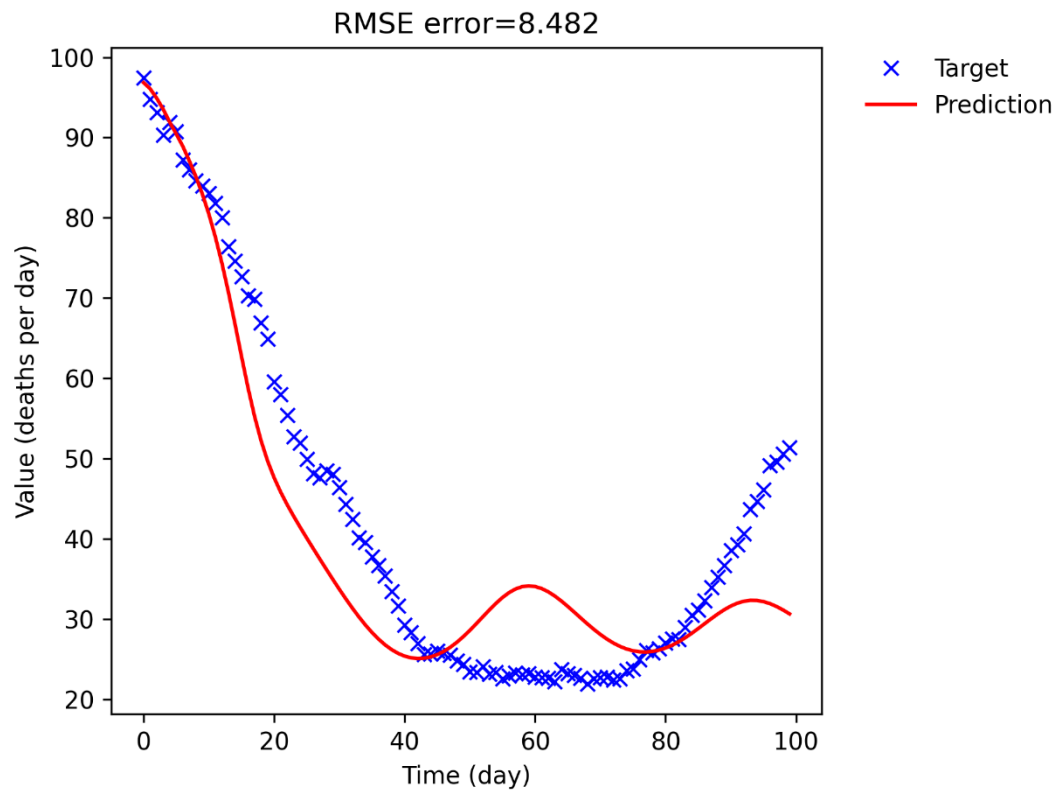


Εικόνα 12: Γράφημα προβλέψεων του νευρωνικού LSTM RNN σε συνάρτηση με τις πραγματικές τιμές.



Εικόνα 13: Γράφημα προβλέψεων θανάτων από COVID-19 κάθε επόμενης ημέρες, με παραχώρηση των δεδομένων των 6 προηγούμενων ημερών (LSTM RNN).

Στο επόμενο σχεδιάγραμμα οι προβλέψεις του LSTM χρησιμοποιούνται διαδοχικά για την πρόβλεψη ολόκληρης της εξέλιξης των θανάτων στο μέλλον (iterative forecasting). Το RMSE είναι 8.482, το μικρότερο σε σχέση με τα δύο άλλα μοντέλα.



Εικόνα 14: Γράφημα προβλέψεων θανάτων από COVID-19 σε διάστημα 100 ημερών, με παραχώρηση των δεδομένων των πρώτων 6 ημερών. (LSTM RNN).

5 Συμπεράσματα

Τα αποτελέσματα υποδεικνύουν ότι το Deep MLP μπορεί να χρησιμοποιηθεί για πρόβλεψη των θανάτων της επόμενης ημέρας, με βάση δεδομένα από έξι προηγούμενες ημέρες. Επίσης μπορεί να περιγράψει και την εξέλιξη των θανάτων για περισσότερες ημέρες με την μέθοδο του iterative forecasting, διαδοχικά χρησιμοποιώντας προβλέψεις στην είσοδο. Το σφάλμα αυξάνεται, αλλά η ποιοτική εξέλιξη μπορεί να αναπαρασταθεί.

Αντίθετα, το RNN, παρόλο που έχει μικρότερο RMSE σφάλμα στην πρόβλεψη της επόμενης ημέρας, δεν πιάνει ούτε ποσοτικά ούτε ποιοτικά την εξέλιξη των θανάτων στο iterative forecasting. Μια πιθανή εξήγηση αυτού του φαινομένου είναι ότι το RNN απομνημονεύει χαρακτηριστικά που είναι σχετικά μόνο με την επόμενη ημέρα, και ως αποτέλεσμα όταν χρησιμοποιείται για την πρόβλεψη για περισσότερες ημέρες, το σφάλμα είναι πολύ μεγαλύτερο.

Τέλος, το LSTM RNN είναι το μοντέλο με το μικρότερο σφάλμα και στην πρόβλεψη των θανάτων της επόμενης ημέρας, και στο iterative forecasting για όλες τις ημέρες.

Συμπερασματικά, το LSTM RNN έχοντας μια πιο περίπλοκη αρχιτεκτονική είναι πιο αποτελεσματικό στο να μπορεί να αναγνωρίσει μοτίβα στα δεδομένα που να γενικεύονται, και μπορεί να χρησιμοποιηθεί για την πρόβλεψη χρονοσειρών σχετικές με θανάτους σε μια πανδημία.

Τα εργαλεία που αναπτύχθηκαν σε αυτή την εργασία μπορούν να εφαρμοστούν για τη πρόβλεψη χρονοσειρών από οποιαδήποτε πηγή, καθώς δεν προϋποθέτουν καμία γνώση των εξισώσεων, ή κάποιου μοντέλου με βάση το οποίο παράχθηκαν τα δεδομένα. Αυτό καθιστά τα εργαλεία αυτά πολύ χρήσιμα στην πράξη.

Βιβλιογραφία

- [1] Bengio, Y.: (2009), Learning deep architectures for AI. Foundations and trends in Machine Learning 2, 1-127
- [2] Farahat, Mahboubeh & Halavati, Ramin. (2016). Noise Robust Speech Recognition Using Deep Belief Networks. International Journal of Computational Intelligence and Applications
- [3] Hochreiter, Sepp, and Jrgen Schmidhuber. (1997) "Long short-term memory." Neural computation
- [4] J. Latif, C. Xiao, A. Imran, and S. Tu, "Medical Imaging using Machine Learning and Deep Learning Algorithms: A Review," in 2019 2nd International Conference on Computing, Mathematics and Engineering Technologies (iCoMET), 2019, pp. 1–5.
- [5] Lewis, T.G. & Denning, P.J. (2018). Learning machine learning. Communications of the ACM, 61(12).
- [6] Min, Seonwoo & Lee, Byunghan & Yoon, Sungroh (2016), Deep Learning in Bioinformatics. Briefings in Bioinformatics,
- [7] Mosavi A., Varkonyi-Koczy A. R. (2017), Integration of Machine Learning and Optimization for Robot Learning. Advances in Intelligent Systems and Computing 519, 349-355
- [8] Mahdavinejad, M.S., Rezvan, M., Barekatain, M., Adibia, P., Barnaghid, P. & Sheth, A.P. (2018). Machine learning for internet of things data analysis: a survey. Elsevier Digital Communications and Networks, August 2018, 4(3), 161-175.
- [9] Mohamed abd el Zaher, Ahmed allah & Eldeib, Ayman. (2015). Breast cancer classification using deep belief networks. Expert Systems with Applications. Σελ. 139-144.
- [10] M. Sewak, S. K. Sahay, and H. Rathore, "Comparison of Deep Learning and the Classical Machine Learning Algorithm for the Malware Detection," in 2018 19th IEEE/ACIS International Conference on Software Engineering, Artificial Intelligence, Networking and Parallel/Distributed Computing (SNPD), 2018, pp.293–296.

- [11] N. G. Paterakis, E. Mocanu, M. Gibescu, B. Stappers, and W. van Alst, "Deep learning versus traditional machine learning methods for aggregated energy demand prediction," in 2017 IEEE PES Innovative Smart Grid Technologies Conference Europe (ISGT-Europe), 2017, pp. 1–6.
- [12] S. Zhou, Q. Chen and X. Wang, "Discriminative Deep Belief Networks for image classification," 2010 IEEE International Conference on Image Processing, Hong Kong, pp. 1561-1564
- [13] Sak, Hasim, Andrew W. Senior, and Franoise Beaufays. (2014) "Long short term memory recurrent neural network architectures for large scale acoustic modeling." Interspeech.
- [14] Jürgen Schmidhuber. (2015) Deep learning in neural networks: An overview. Neural Networks, 61:85–117
- [15] Nielsen, M. (2015). Neural Network and Deep Learning. Determination Press.
- [16] Πλεύρου, Α. (2012). Τεχνητά νευρωνικά δίκτυα προσομοίωσης του ανθρώπινου Εγκεφάλου
- [17] Thomas, A. (2018). A brief introduction to LSTM networks. Adventures in machine learning.
- [18] Yu, Li, Dong, & Deng. (2014). Deep Learning - Methods and Applications.
- [19] Pengfei L. Xipeng Q. Xuanjing H. (2016) Recurrent Neural Network for Text Classification with Multi-Task Learning.

